Python 3 玩儿转机器学习

liuyubobobo

机器学习基础概念

关于数据

数据

- 著名的鸢尾花数据 https://en.wikipedia.org/wiki/Iris_flower_data_set

Iris setosa

Iris versicolor

Iris verginica

数据

```
Iris Plants Database
====================

Notes
-----
Data Set Characteristics:
    :Number of Instances: 150 (50 in each of three classes)
    :Number of Attributes: 4 numeric, predictive attributes and the class
    :Attribute Information:
        - sepal length in cm
        - sepal width in cm
        - petal length in cm
        - petal width in cm
        - class:
                - Iris-Setosa
                - Iris-Versicolour
                - Iris-Virginica
```

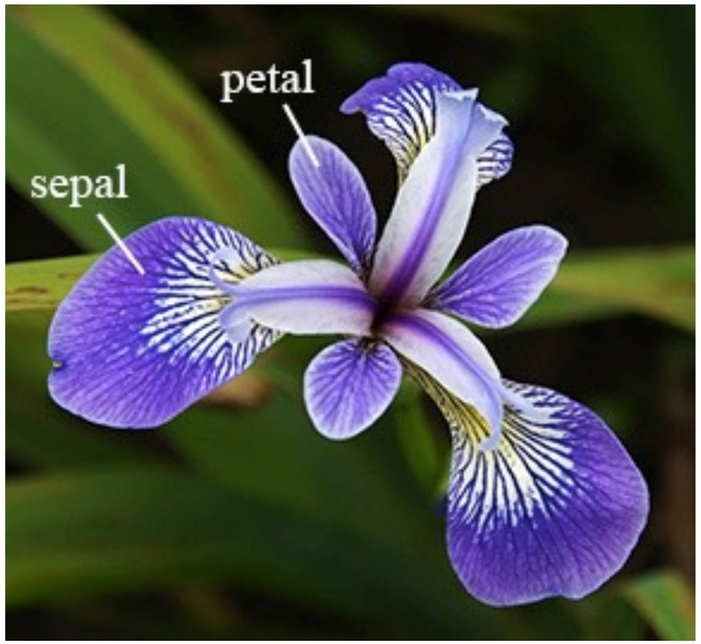

数据

萼片长度	萼片宽度	花瓣长度	花瓣宽度	种类
5.1	3.5	1.4	0.2	se (0)
7.0	3.2	4.7	1.4	ve (1)
6.3	3.3	6	2.5	vi (2)

数据

萼片长度	萼片宽度	花瓣长度	花瓣宽度	种类
5.1	3.5	1.4	0.2	se (0)
7.0	3.2	4.7	1.4	ve (1)
6.3	3.3	6	2.5	vi (2)

X

y

- 数据整体叫数据集 (data set)
- 每一行数据称为一个样本(sample)
- 除最后一列，每一列表达样本的一个特征(feature)
- 最后一列，称为标记(label)

第i个样本行写作 $X^{(i)}$ 第i个样本第j个特征值 $X_j^{(i)}$ 第i个样本的标记写作 $y^{(i)}$

数据

萼片长度	萼片宽度	花瓣长度	花瓣宽度
5.1	3.5	1.4	0.2
7.0	3.2	4.7	1.4
6.3	3.3	6	2.5

→ 特征

→ 特征向量 $X^{(i)}$

$$\begin{pmatrix} 5.1 \\ 3.5 \\ 1.4 \\ 0.2 \end{pmatrix}$$

$$\begin{pmatrix} (X^{(1)})^T \\ (X^{(2)})^T \\ (X^{(3)})^T \\ \cdots \end{pmatrix}$$

数据

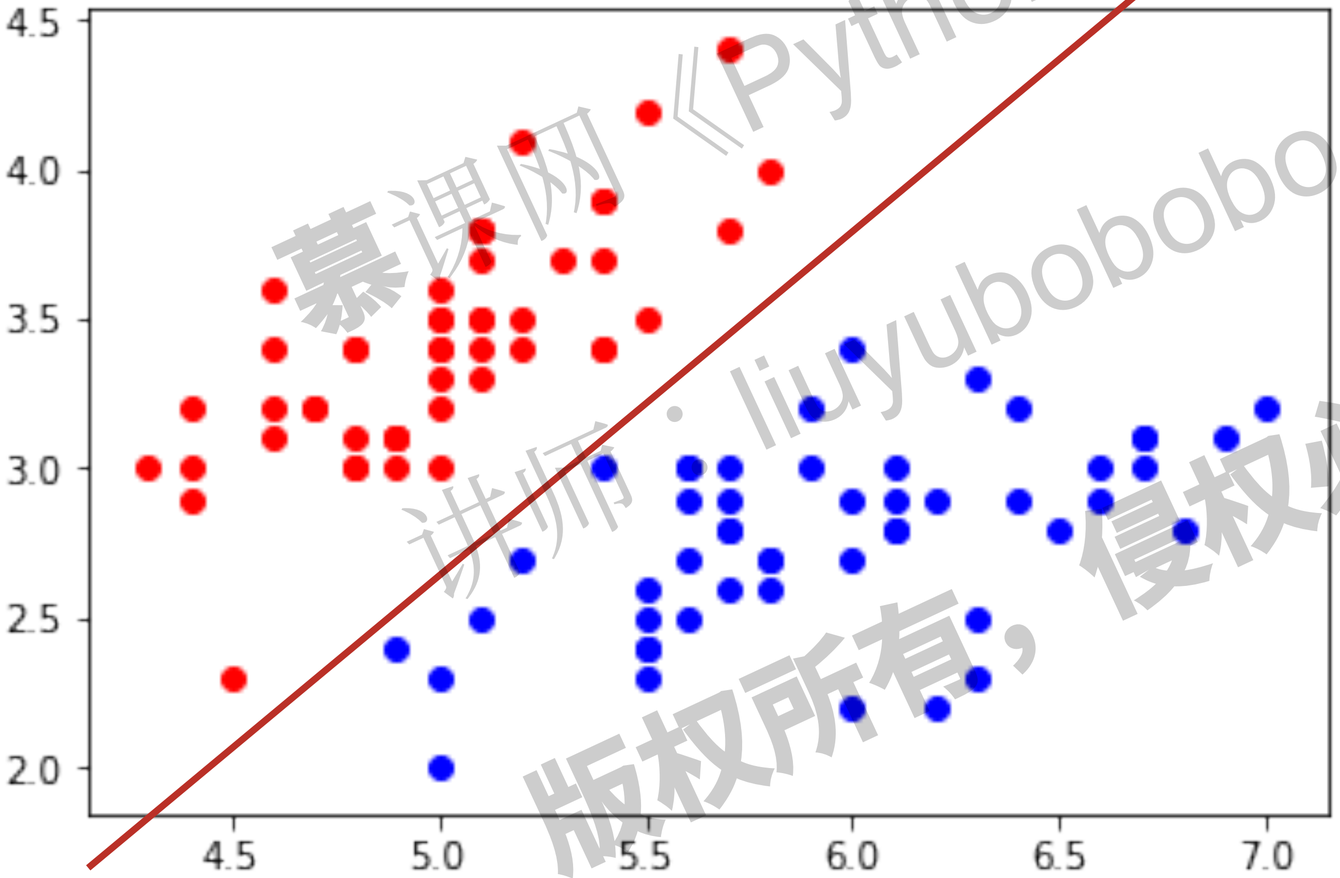

- 特征空间 (feature space)
- 分类任务本质就是在特征空间切分
- 在高维空间同理

特征可以很抽象

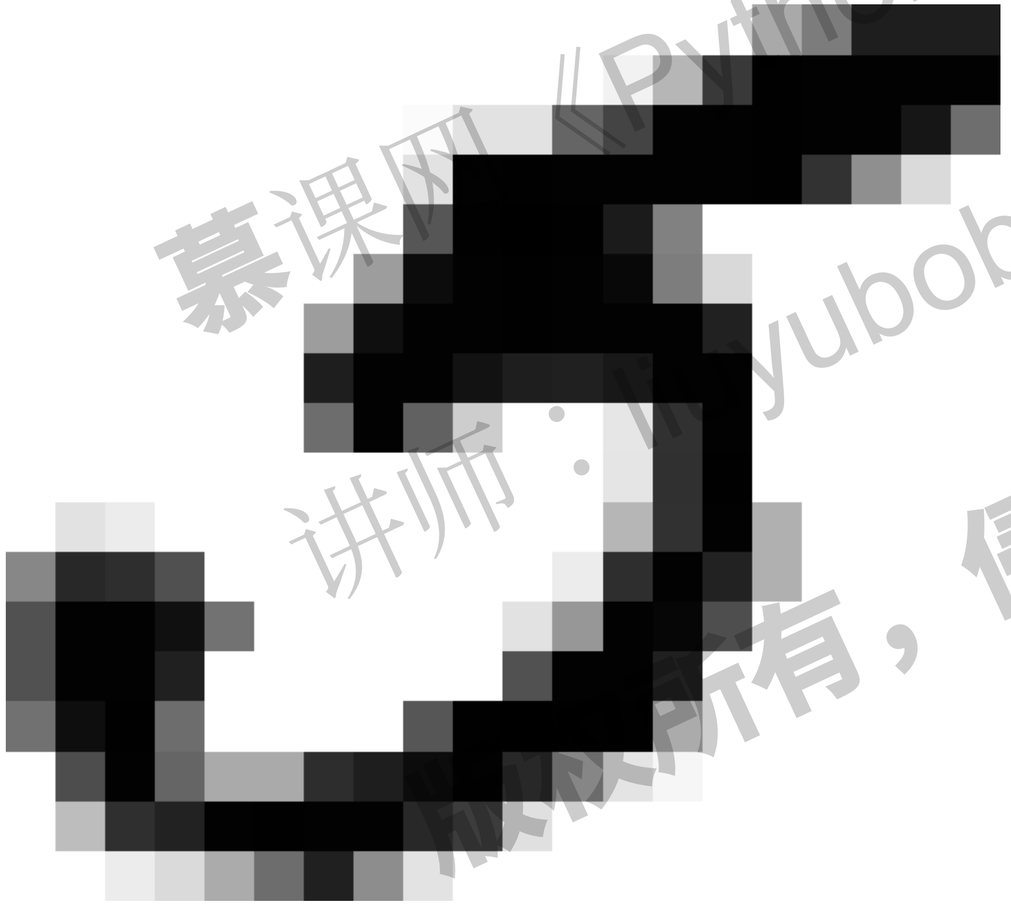

- 图像，每一个像素点都是特征
- 28*28的图像有28*28=784个特征
- 如果是彩色图像特征更多

机器学习的基本任务

机器学习的基本任务

- 分类
- 回归

分类任务

分类任务

分类任务

- 二分类

- 判断邮件是垃圾邮件；不是垃圾邮件
- 判断发放给客户信用卡有风险；没有风险
- 判断病患良性肿瘤；恶性肿瘤
- 判断某支股票涨；跌

分类任务

- 多分类

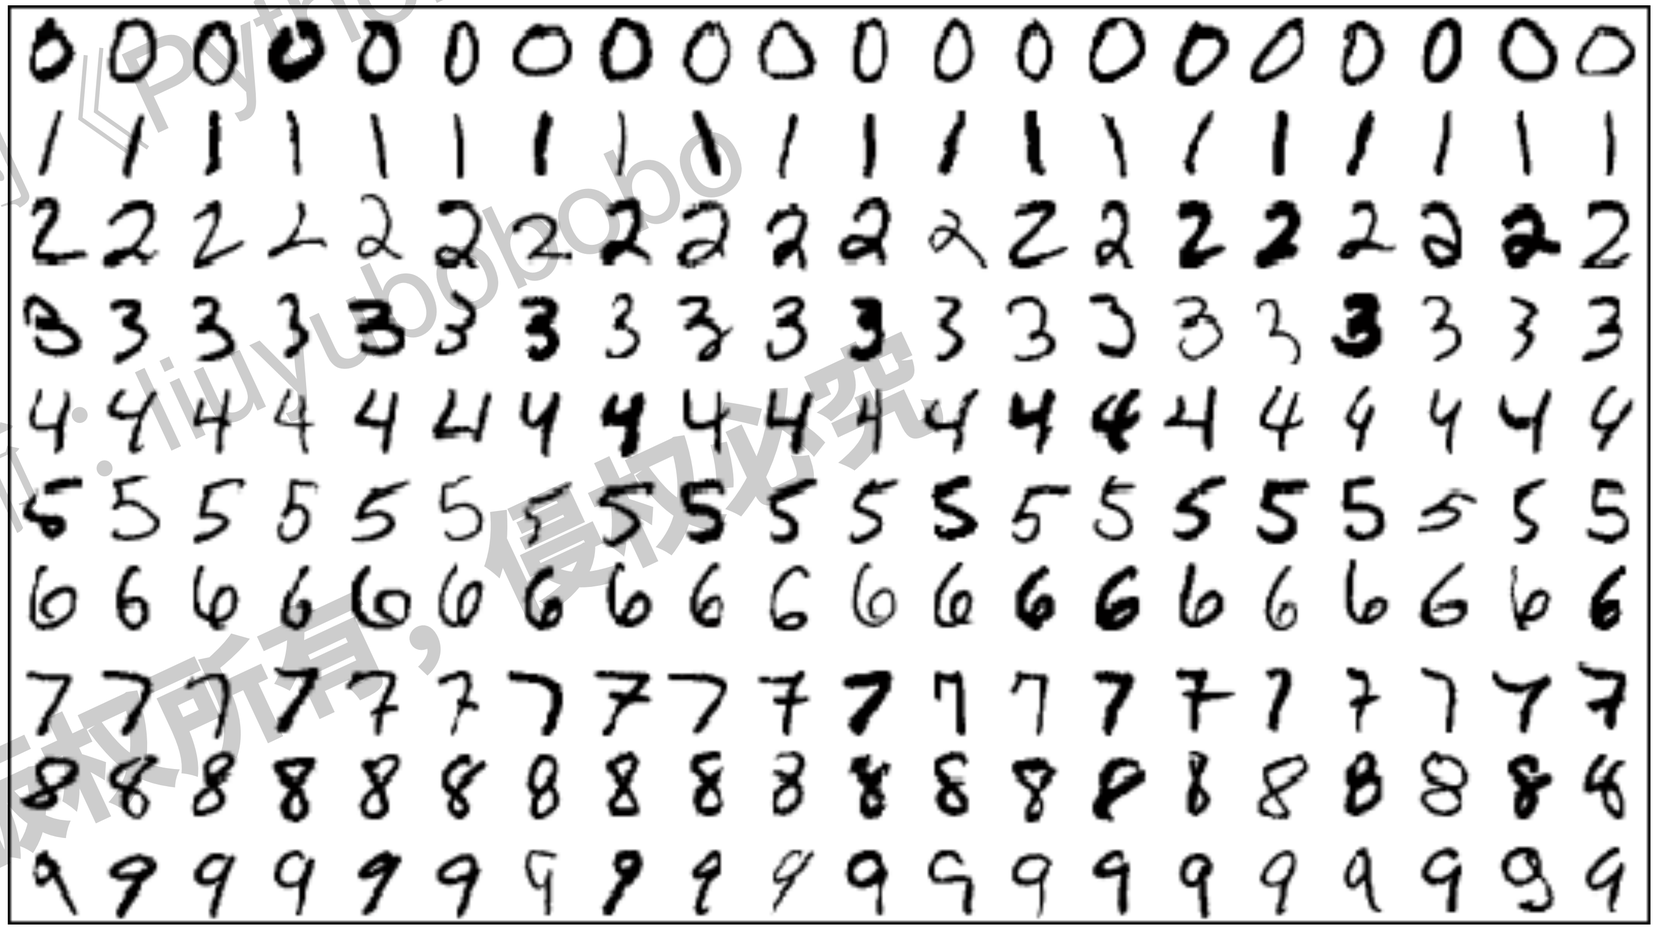

分类任务

- 多分类
  - 数字识别
  - 图像识别
  - 判断发放给客户信用卡的风险评级

分类任务

- 多分类

- 很多复杂的问题也可以转换成多分类问题

分类任务

- 多分类

分类任务

- 多分类

分类任务

- 多分类
  - 一些算法只支持完成二分类的任务
  - 但是多分类的任务可以转换成二分类的任务
  - 有一些算法天然可以完成多分类任务

分类任务

- 多标签分类

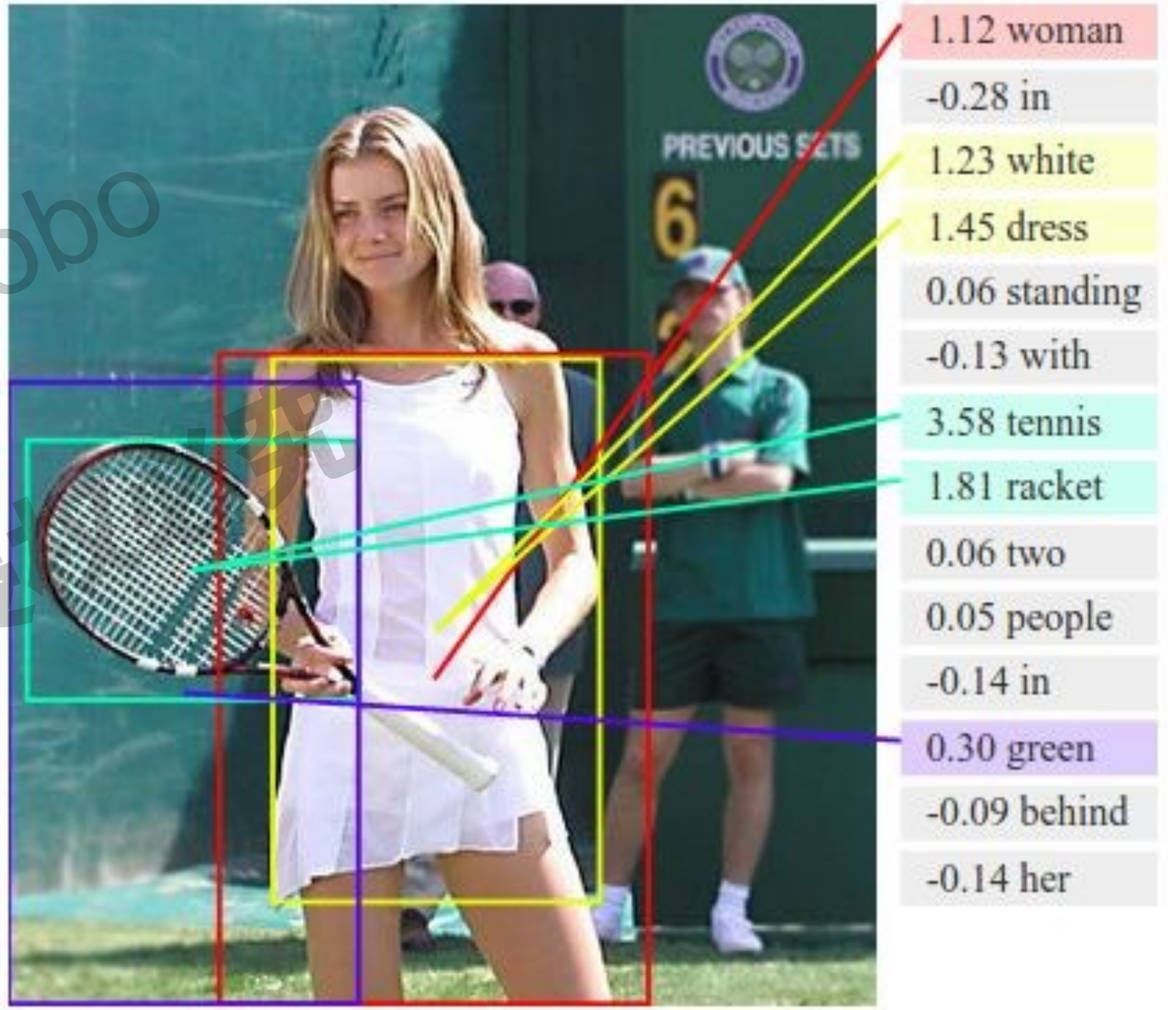

另一类数据

房屋面积（平方米）	房屋年龄（年）	卧室数量（间）	最近地铁站距离(千米)	价格（万元）
80	3	1	10	300
120	8	3	5	500
200	5	4	12	700

回归任务

- 结果是一个连续数字的值，而非一个类别
  - 房屋价格
  - 市场分析
  - 学生成绩
  - 股票价格

回归任务

- 结果是一个连续数字的值，而非一个类别
  - 有一些算法只能解决回归问题
  - 有一些算法只能解决分类问题
  - 有一些算法的思路既能解决回归问题，又能解决分类问题

回归任务

- 一些情况下，回归任务可以简化成分类任务

机器学习的基本任务

- 分类
- 回归

什么是机器学习

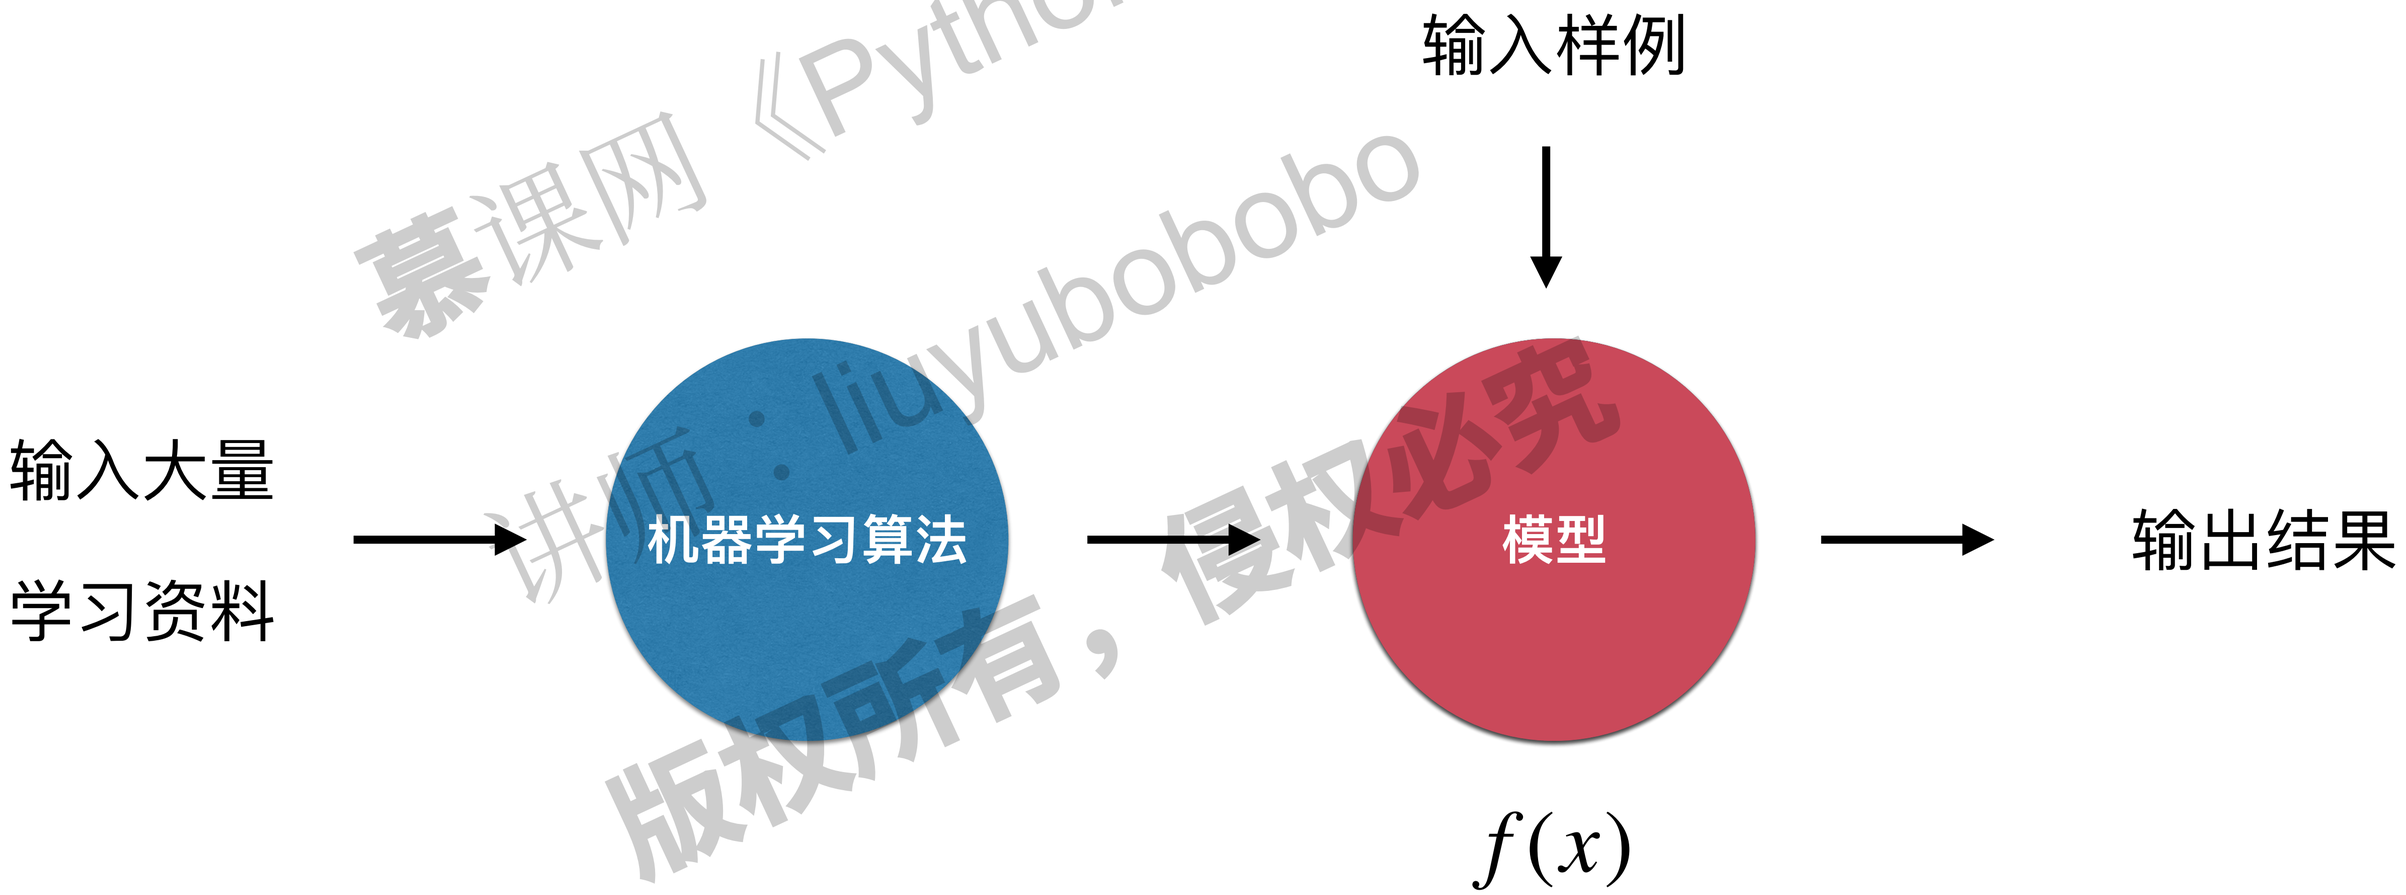

监督学习

- 分类
- 回归

监督学习，非监督学习
半监督学习 和 增强学习

机器学习方法的分类

- 监督学习
- 非监督学习
- 半监督学习
- 增强学习

监督学习

给机器的训练数据拥有“标记”或者“答案”

狗

猫

监督学习

MNIST数据集

监督学习

- 图像已经拥有了标定信息
- 银行已经积累了一定的客户信息和他们信用卡的信用情况
- 医院已经积累了一定的病人信息和他们最终确诊是否患病的情况
- 市场积累了房屋的基本信息和最终成交的金额
- ……

监督学习

- 分类
- 回归

监督学习

我们在这个课程中学习的大部分算法，属于监督学习算法

- k近邻
- 线性回归和多项式回归
- 逻辑回归
- SVM
- 决策树和随机森林

非监督学习

给机器的训练数据没有任何“标记”或者“答案”

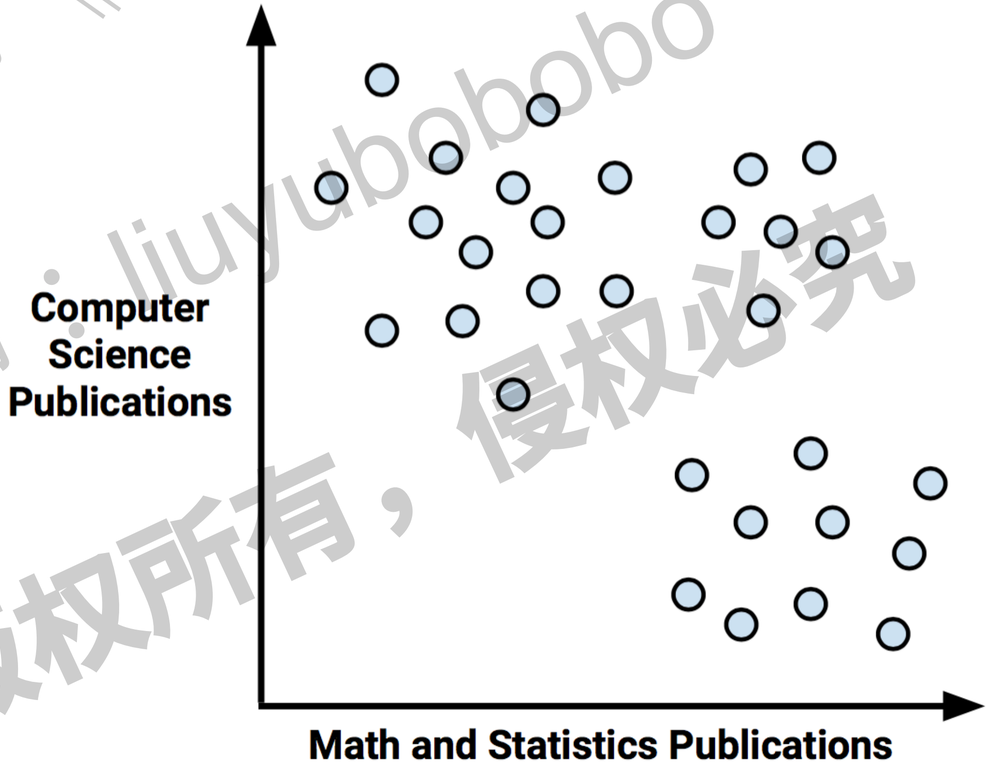

非监督学习的意义

对没有“标记”的数据进行分类 - 聚类分析

非监督学习的意义

对数据进行降维处理

- 特征提取：信用卡的信用评级和人的胖瘦无关?
- 特征压缩：PCA

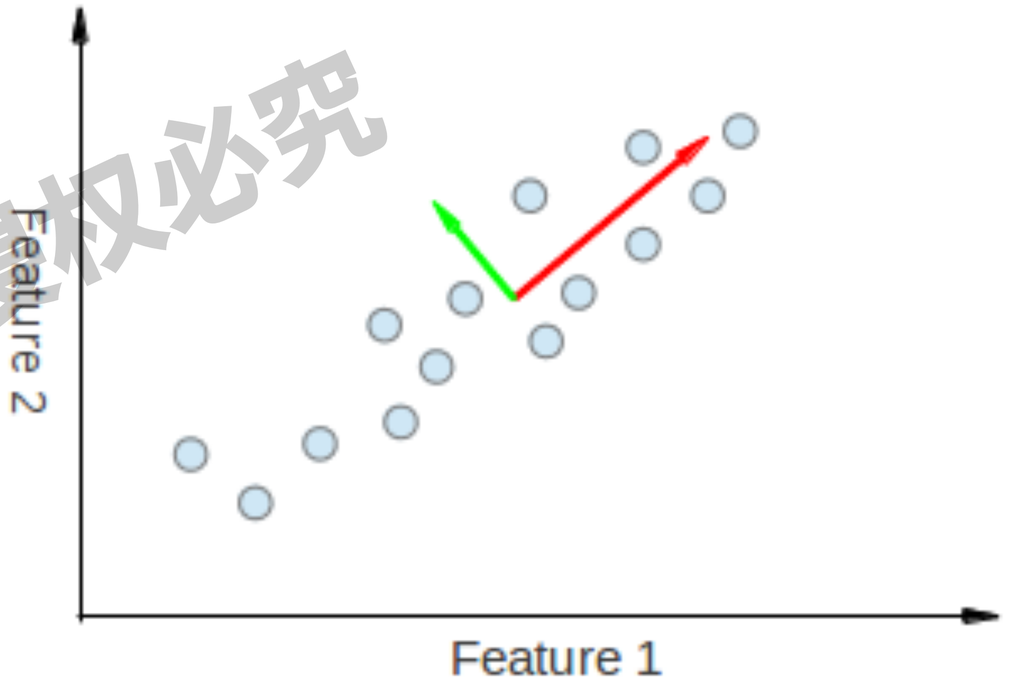

非监督学习的意义

降维处理的意义：方便可视化

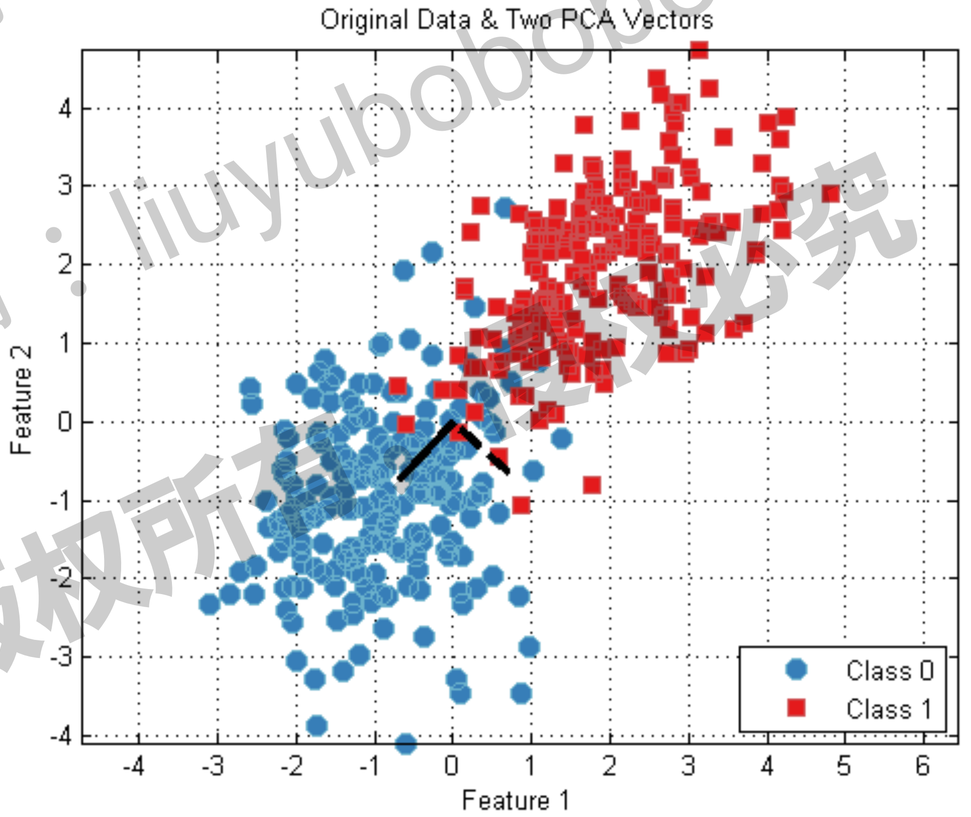

非监督学习的意义

异常检测

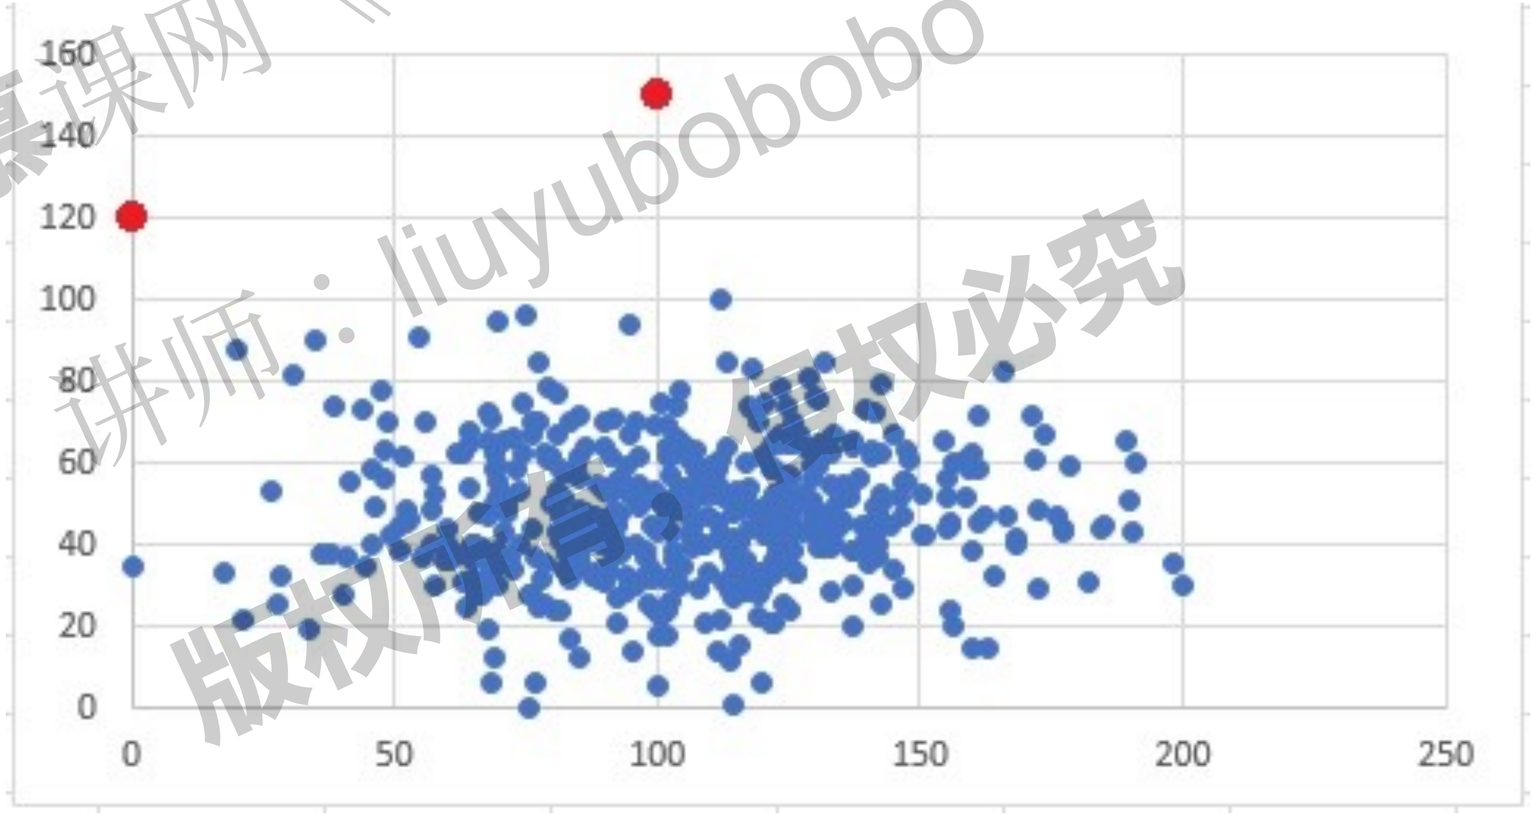

半监督学习

一部分数据有“标记”或者“答案”，另一部分数据没有

更常见：各种原因产生的标记缺失

通常都先使用无监督学习手段对数据做处理，之后使用监督学习手段做模型的训练和预测

增强学习

根据周围环境的情况，采取行动，根据采取行动的结果，学习行动方式。

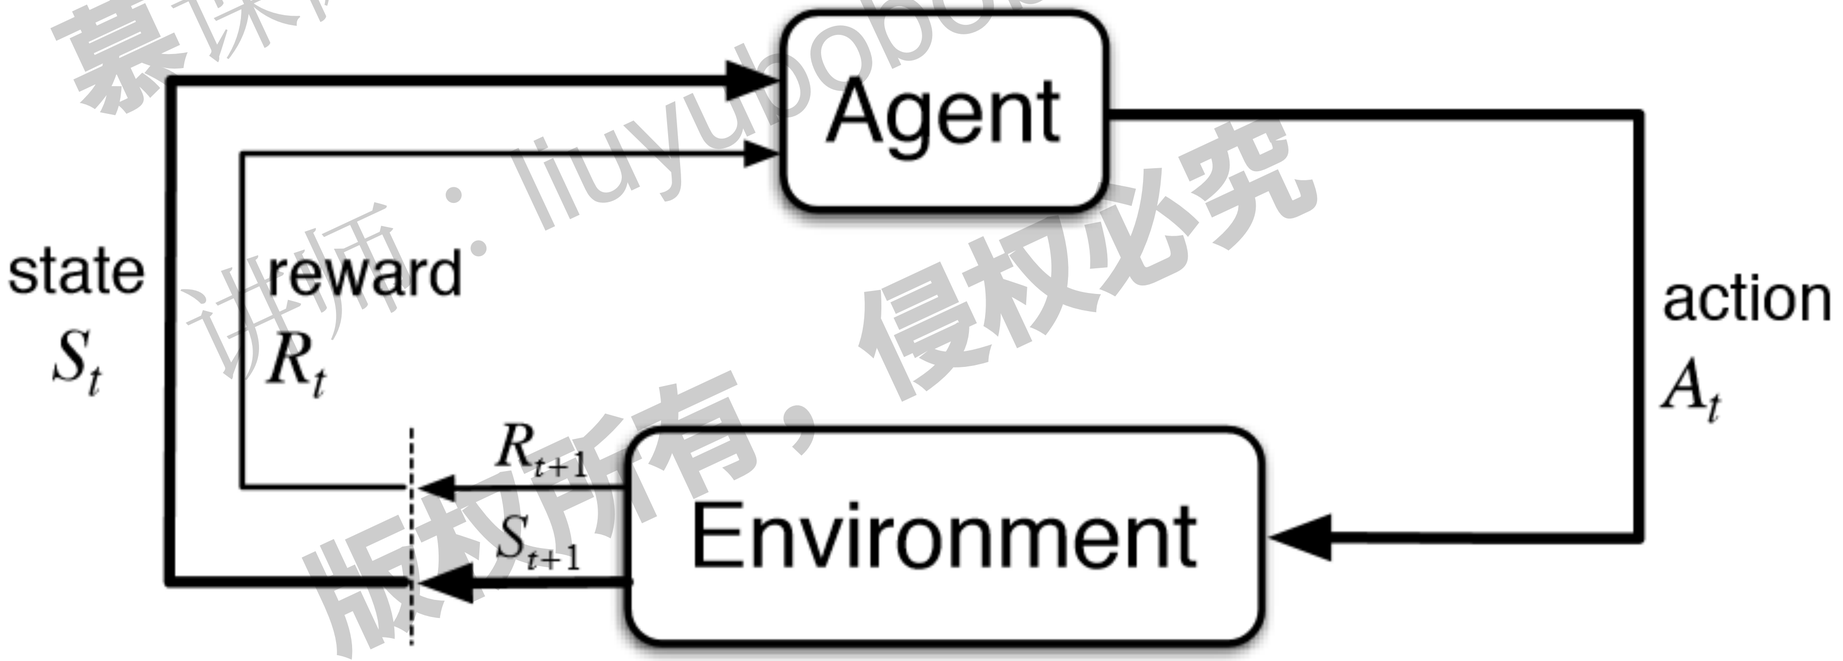

增强学习


Google DeepM
Challenge Ma
8 - 15 March 2
10
BREAKTHROUGH
TECHNOLOGIES
AlphaGo
Lee Sedol

增强学习

无人驾驶

机器人

监督学习和半监督学习是基础

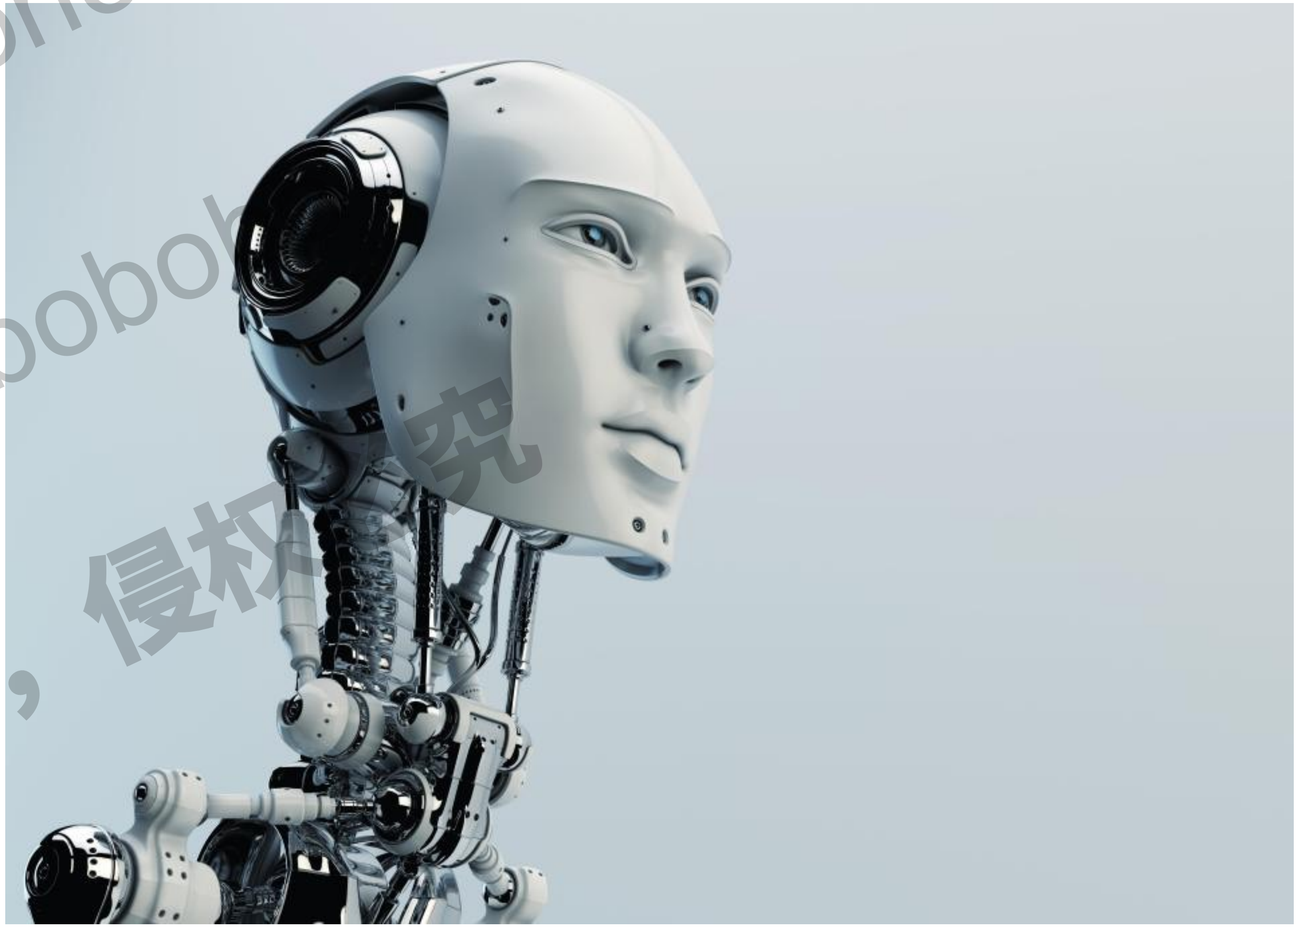

机器学习方法的分类

- 监督学习
- 非监督学习
- 半监督学习
- 增强学习

机器学习的其他分类

在线学习和批量学习（离线学习）

参数学习和非参数学习

批量学习和在线学习

- 批量学习 Batch Learning
- 在线学习 Online Learning

批量学习

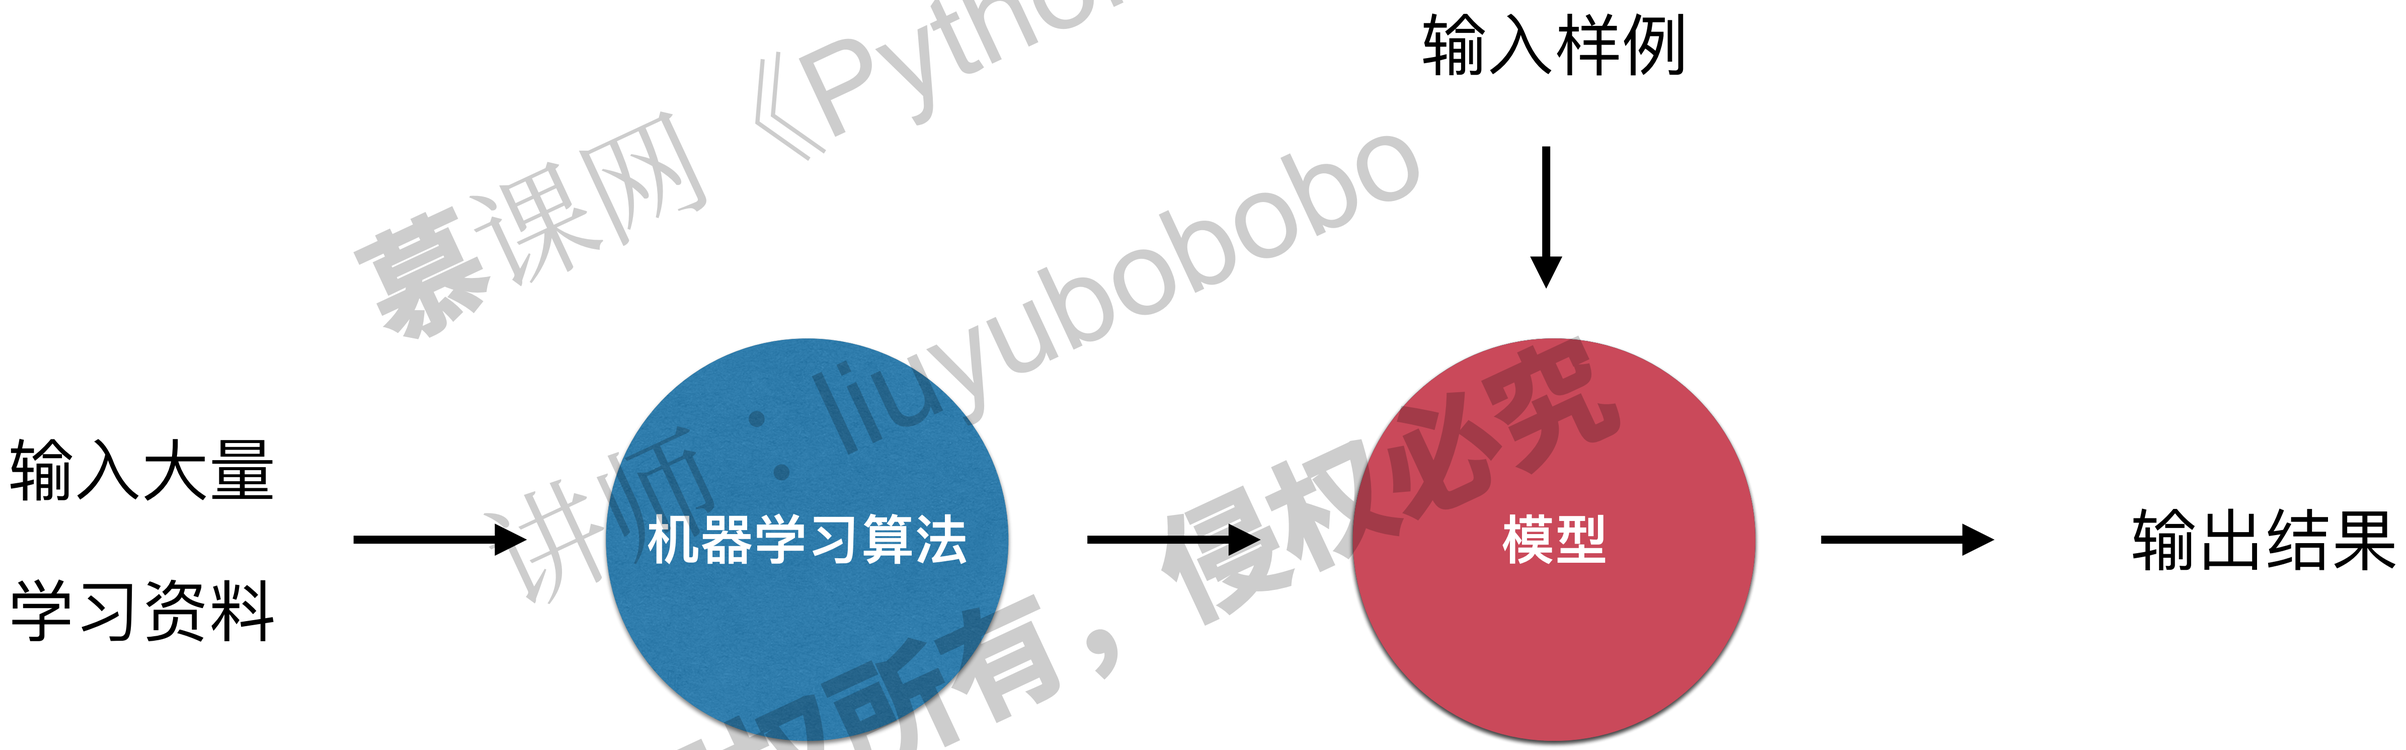

批量学习

- 优点：简单
- 问题：如何适应环境变化？

  解决方案：定时重新批量学习
- 缺点：每次重新批量学习，运算量巨大；

  在某些环境变化非常快的情况下，甚至不可能的。

在线学习

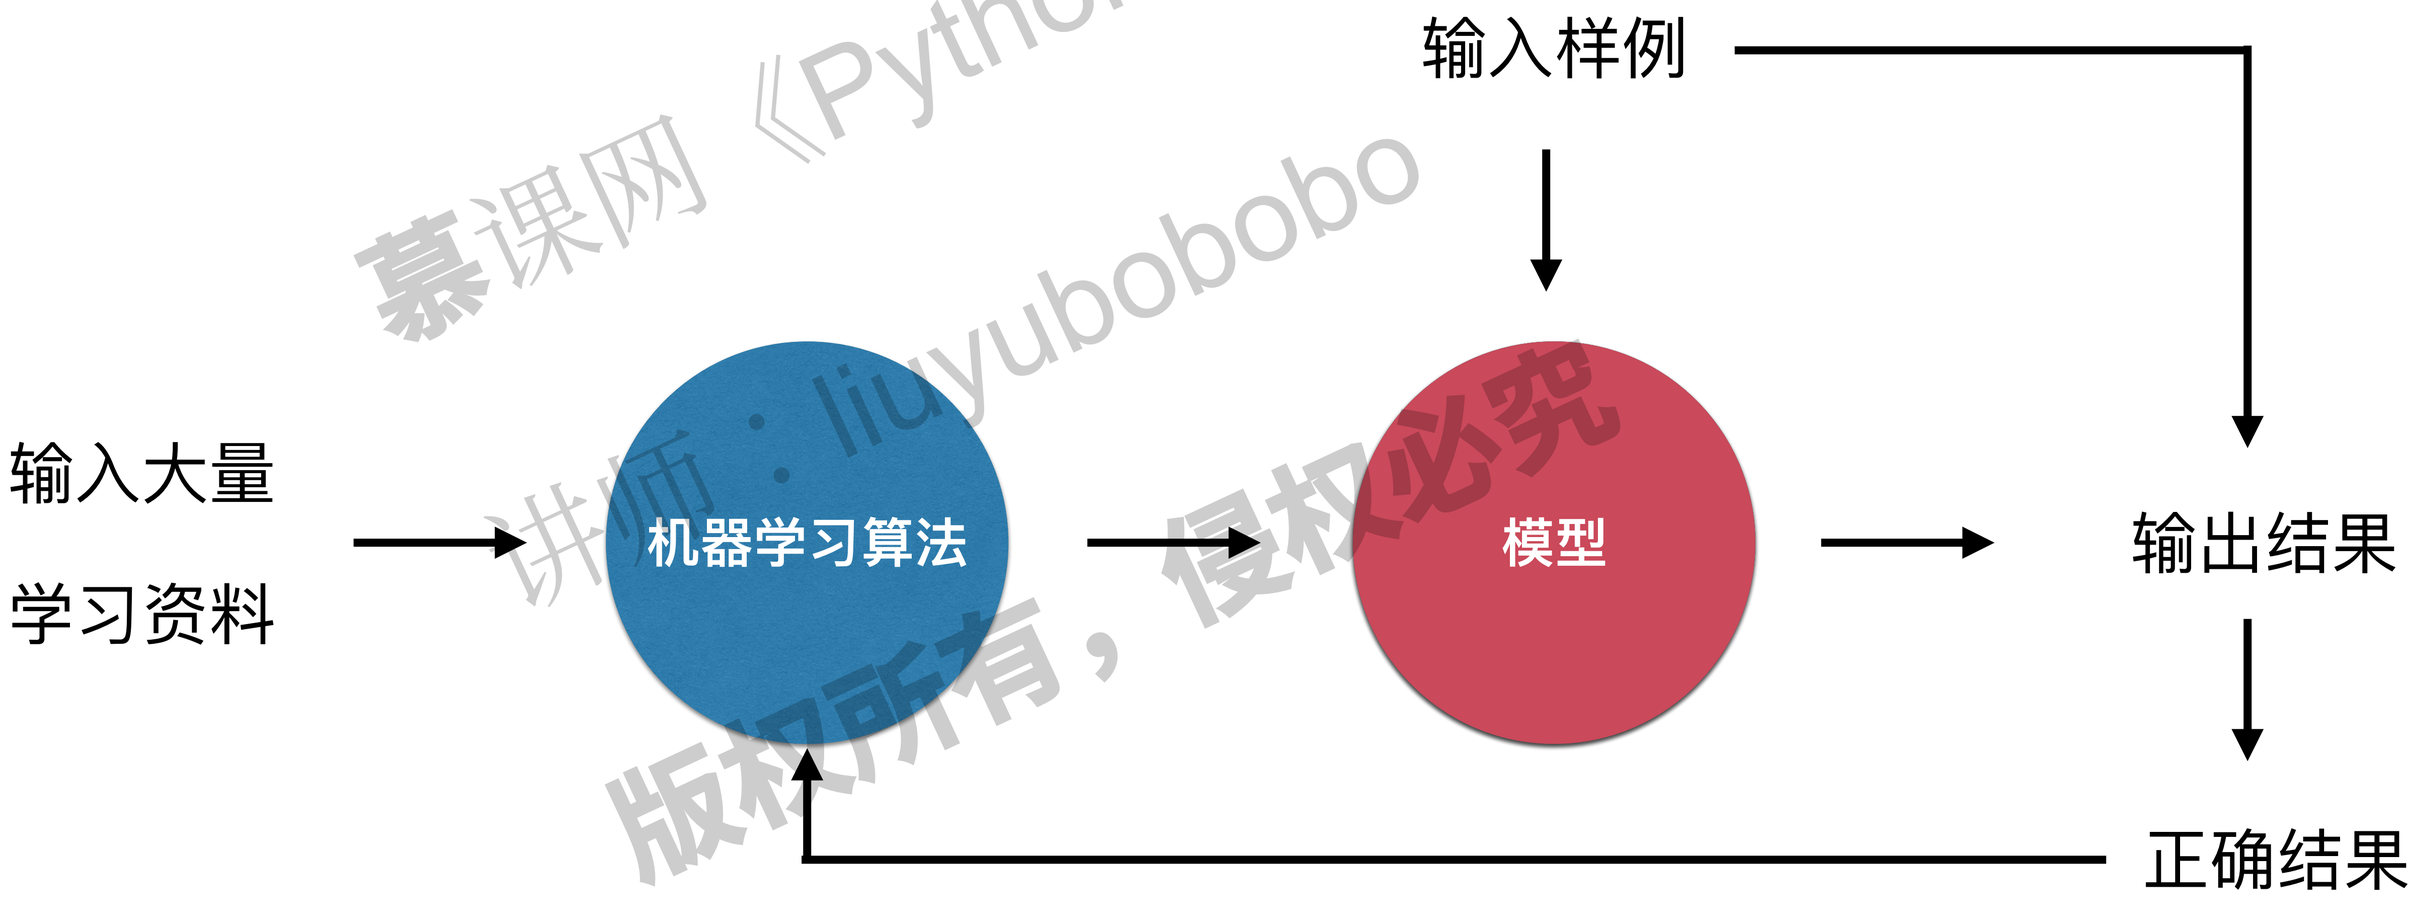

在线学习

- 优点：及时反映新的环境变化
- 问题：新的数据带来不好的变化?

  解决方案：需要加强对数据进行监控
- 其他：也适用于数据量巨大，完全无法批量学习的环境。

参数学习和非参数学习

- 参数学习 Parametric Learning
- 非参数学习 Nonparametric Learning

参数学习

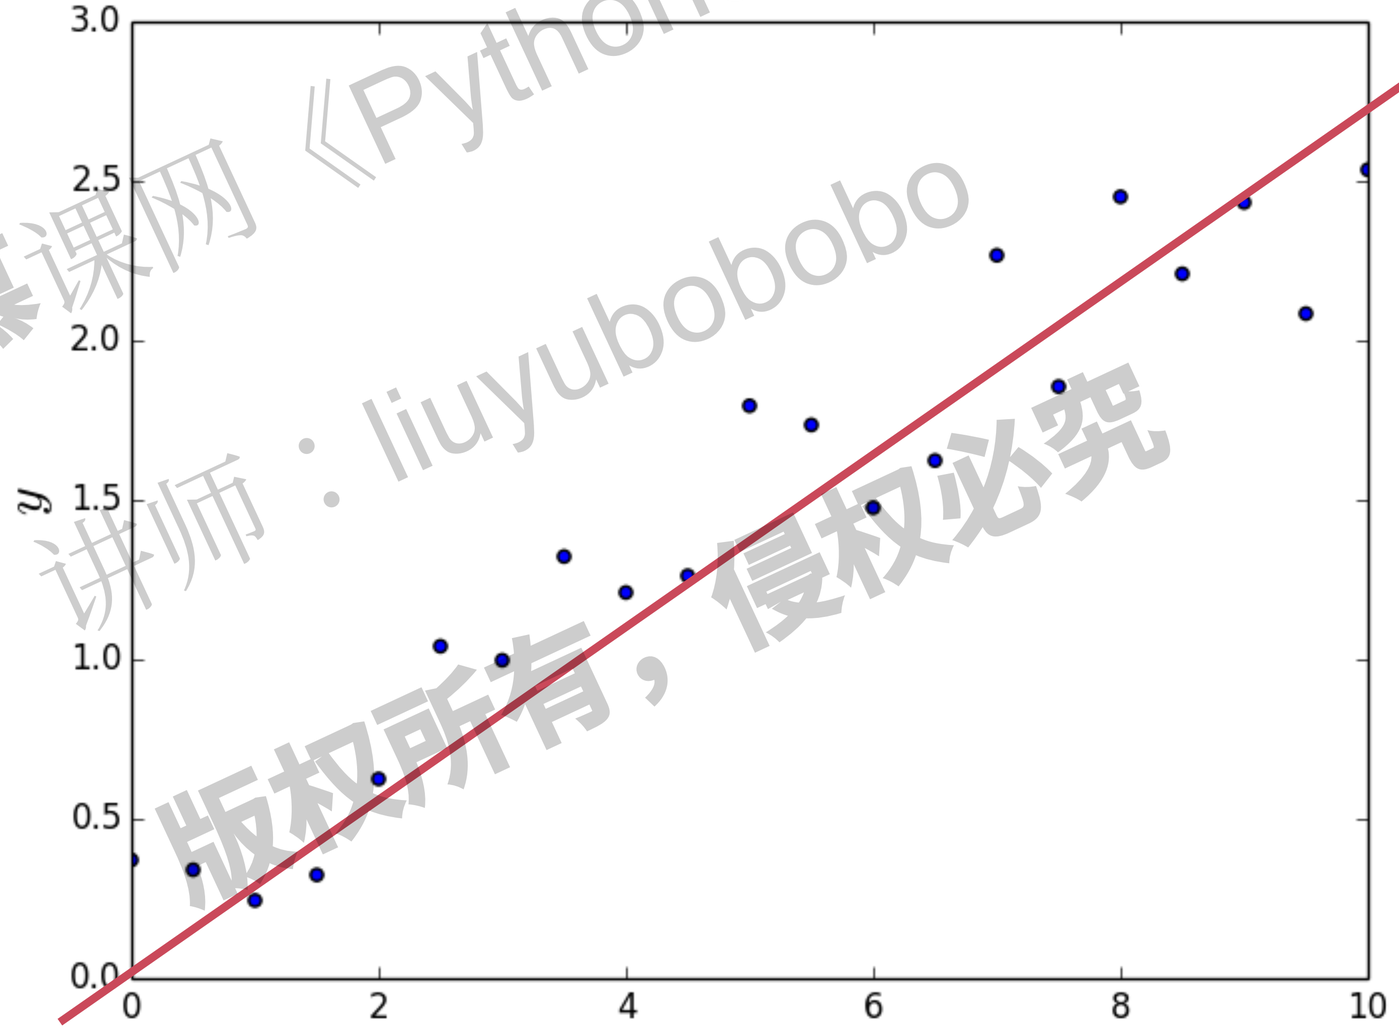

f(x) = a*x + b

参数学习的特点

一旦学到了参数，就不再需要原有的数据集

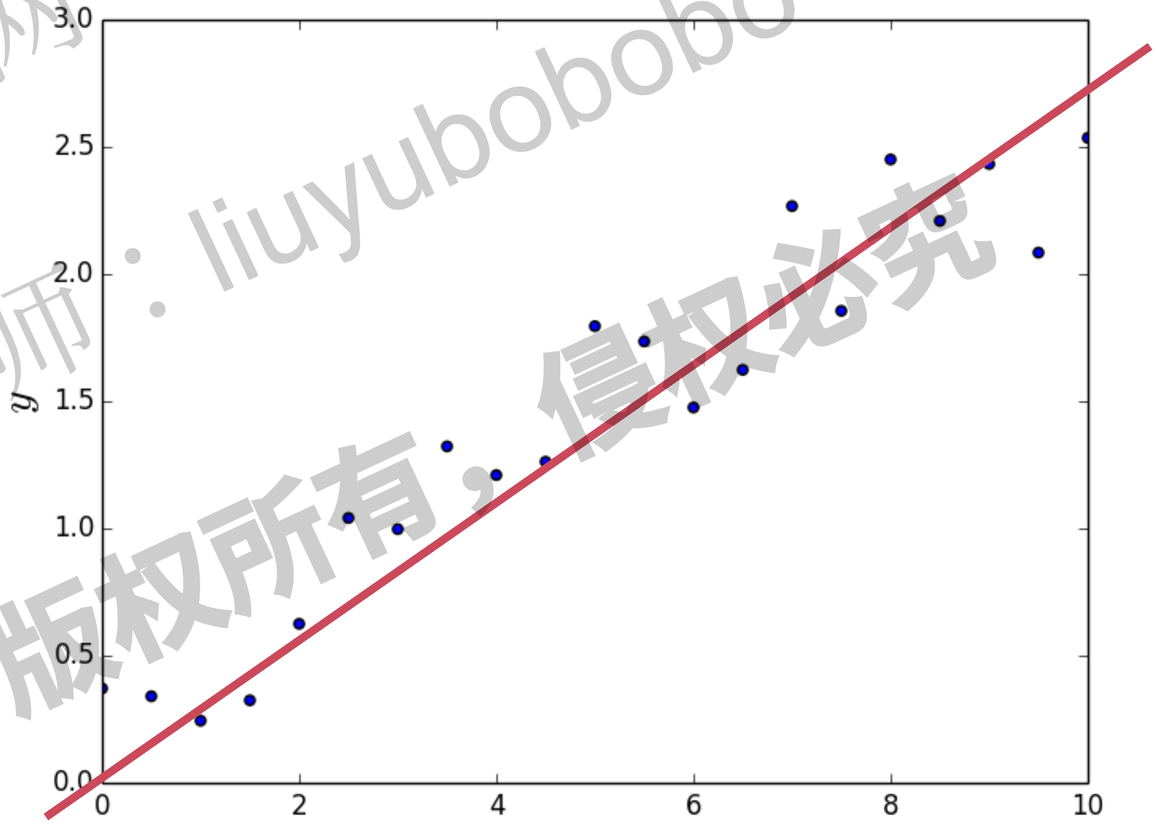

非参数学习

- 不对模型进行过多假设
- 非参数不等于没参数！

和机器学习相关的“哲学”思考

2001年，

微软的论文

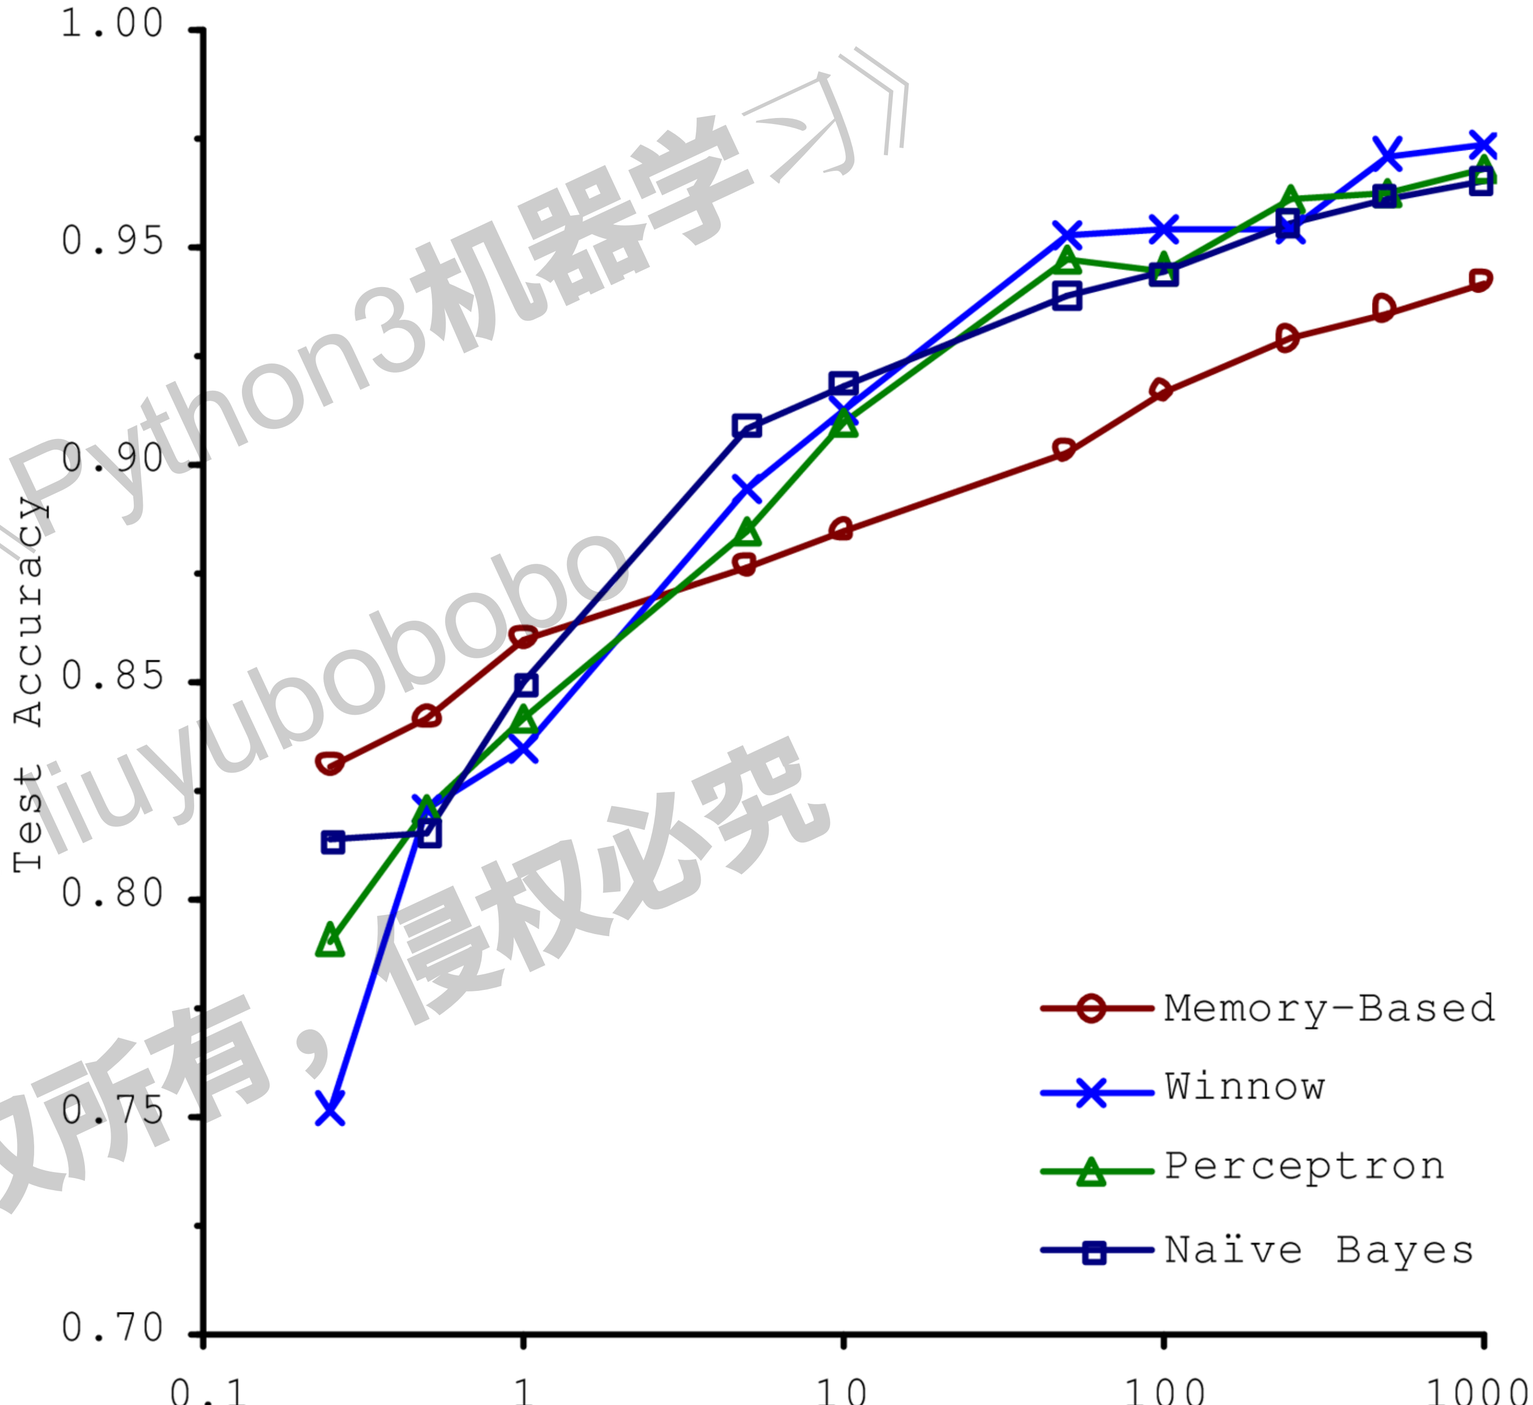

数据即算法?

数据即算法？

- 数据确实非常重要
- 数据驱动

- 收集更多的数据
- 提高数据质量
- 提高数据的代表性
- 研究更重要的特征

算法为王?

如何选择机器学习算法?

- kNN
- 线性回归
- 多项式回归
- 逻辑回归
- 模型正则化
- PCA
- SVM
- 决策树
- 随机森林
- 集成学习
- 模型选择
- 模型调试

奥卡姆的剃刀

- 简单的就是好的
- 到底在机器学习领域，什么叫“简单”？

没有免费的午餐定理

- 可以严格地数学推导出：任意两个算法，他们的期望性能是相同的！
- 具体到某个特定问题，有些算法可能更好
- 但没有一种算法，绝对比另一种算法好

没有免费的午餐定理

- 脱离具体问题，谈那个算法好是没有意义的。
- 在面对一个具体问题的时候，尝试使用多种算法进行对比试验，是必要的。

其他思考

面对不确定的世界，怎么看待使用机器学习进行预测的结果？

课程环境搭建

ANACONDA®

课程github

github.com/liuyubobobo/Play-with-Machine-Learning-Algorithms

其他

请大家善于使用慕课网的课程问答区

其他

欢迎大家关注我的个人公众号：是不是很酷

Python 3 玩儿转机器学习

liuyubobobo